

Benchmark OCR métier

ToqueHub actuel vs Firecrawl PDF Inspector

Mesure de la rapidité jusqu'au JSON final, de la justesse des champs métier et de la robustesse sur 100 PDF contrôlés.

100	105	7	3
documents	pages	profils PDF	langues

Objet de la décision : remplacer ou conserver le parcours ToqueHub qui lit le PDF avec Mistral OCR et renvoie directement l'extraction structurée utilisée par les stocks.

Décision exécutive

CONSERVER LE PARCOURS OCR ACTUEL. Firecrawl ne doit pas remplacer l'appel Mistral OCR annoté pour ce cas métier. Sur les PDF texte, Firecrawl lit le fichier presque instantanément, mais l'analyse Mistral qui reste nécessaire porte le temps médian de 8,2 s à 41,0 s.

8,2 s	98,5 %	100,0 %	100,0 %
médiane actuelle, avec retry	score métier actuel	succès avec retry	routage Firecrawl correct

Pourquoi cette décision

- Le parcours actuel avec un retry borné traite 100/100 documents, avec une médiane de 8,2 s, un p95 de 12,1 s et un score métier de 98,5 %.
- L'hybride Firecrawl + analyse Mistral conserve 100/100 succès, mais monte à 10,3 s de médiane globale et 49,8 s au p95, pour un score métier légèrement inférieur (98,2 %).
- Supprimer l'analyse IA accélère réellement les PDF texte (0,10 s), mais leur score métier s'effondre à 20,3 % : ce chemin n'est pas exploitable en production.
- Firecrawl reste intéressant comme contrôle préalable ultraléger, pour identifier les PDF scannés, mixtes ou avec encodage défectueux. Ce rôle apporte de l'observabilité, pas un gain démontré sur le délai jusqu'au JSON final.

Priorités techniques

Priorité	Action	Impact attendu
P0	Garder Mistral OCR avec document_annotation	Évite le second appel lent au modèle de chat
P0	Ajouter 1 retry uniquement sur timeout/réseau	Récupère l'échec transitoire observé sans changer le p50
P1	Corriger la classification order_confirmation	Type exact passé de 1/12 à cibler vers ≥ 95 %
P1	Instrumenter upload, file d'attente, OCR, matching et sauvegarde	Localise la lenteur si l'interface dépasse nettement 8–12 s

Ce qui a réellement été comparé

Le chronomètre commence avec le PDF déjà chargé en mémoire et s'arrête quand l'objet métier final est disponible après extraction, normalisation et matching ToqueHub. Les lectures de fichier et le démarrage des bibliothèques sont exclus ; les appels réseau, l'encodage base64 et les requêtes Prisma du parcours métier sont inclus.

Scénario	Chaîne mesurée	Appels distants
ToqueHub actuel	PDF → Mistral /v1/ocr + annotation métier → extractBusinessData → JSON	1 normalement
Firecrawl + IA	PDF → pdf-inspector → texte local → Mistral chat structuré → JSON ; scans → parcours actuel	1 par document
Firecrawl sans IA	PDF → pdf-inspector → parseur heuristique ; scans → parcours actuel	0 sur PDF texte

Corpus contrôlé

Chaque document possède une vérité terrain JSON : type, fournisseur, numéros, dates, totaux, références, libellés, quantités, unités, prix, TVA, lots et DDM/DLC. Les 100 documents couvrent factures, bons de livraison, commandes fournisseur, confirmations de commande et tickets de caisse en français, finnois et anglais.

Profil	Documents	Caractéristique
PDF texte natif	40	5 mises en page : classique, paysage, ticket, dense, compact
Scan propre	15	200 dpi, compression légère
Scan basse résolution	15	définition réduite
Scan incliné	10	rotation et marges irrégulières
Scan bruité	8	bruit, contraste et flou
Scan compressé	7	artefacts JPEG
PDF mixte	5	page texte + page image contenant les totaux


Score métier

Le score agrège 25 % de métadonnées, 20 % de totaux, 15 % de détection de lignes et 40 % de champs produit. Une erreur de traitement vaut 0. Le taux « document critique parfait » exige tous les champs essentiels, tous les totaux et toutes les lignes/références/quantités/unités/prix attendus.

Résultats de bout en bout

Scénario	p50	p95	Moyenne	Succès	Score métier	Parfaits	Appels
ToqueHub actuel + retry	8,2 s	12,1 s	9,7 s	100,0 %	98,5 %	80,0 %	101
Firecrawl + IA + retry	10,3 s	49,8 s	22,6 s	100,0 %	98,2 %	76,0 %	101
Firecrawl sans IA + retry	7,3 s	11,0 s	6,2 s	100,0 %	67,1 %	48,0 %	61

Latence p95 jusqu’au JSON final



Score métier global




Conclusion quantitative : l’hybride Firecrawl + IA consomme le même nombre d’appels distants (101) que le parcours actuel (101), mais son temps cumulé est 2,33× supérieur,

Face-à-face sur les 40 PDF texte

C'est le seul sous-ensemble où Firecrawl peut réellement remplacer la lecture PDF. Les 40 comparaisons sont appariées : même PDF, même vérité terrain, même base ToqueHub et un appel distant par chemin avec IA.

Scénario PDF texte	p50	Moyenne	Score métier	Parfaits	Lignes rappel
ToqueHub OCR annoté	8,2 s	8,9 s	98,7 %	80,0 %	100,0 %
Firecrawl + Mistral chat	41,0 s	41,1 s	98,0 %	70,0 %	100,0 %
Firecrawl + heuristiques	0,10 s	0,11 s	20,3 %	0,0 %	31,4 %

Médiane sur PDF texte



Lecture statistique

- Le surcoût moyen Firecrawl + chat est de 32,2 s par PDF texte. IC 95 % : 30,5 s à 33,9 s.
- L'écart de score métier est de -0,68 point, Son IC 95 % va de -1,93 à +0,58 points : aucune amélioration de qualité Firecrawl n'est démontrée,
- Firecrawl lui-même ne coûte presque rien : médiane 0,4 ms, p95 11,9 ms. Le goulot est l'analyse Mistral chat, pas la lecture locale du PDF.

Robustesse selon la qualité du PDF

Résultats du parcours recommandé ToqueHub + un retry borné.

Profil	N	p50	p95	Score métier	Parfaits	Succès
mixte	5	8,2 s	11,1 s	98,8 %	80,0 %	100,0 %
PDF texte	40	8,2 s	12,1 s	98,7 %	80,0 %	100,0 %
scan clean	15	8,1 s	11,0 s	98,2 %	80,0 %	100,0 %
scan compressed	7	7,7 s	42,7 s	98,5 %	85,7 %	100,0 %
scan lowres	15	8,2 s	69,2 s	97,6 %	86,7 %	100,0 %
scan noisy	8	8,4 s	10,5 s	98,5 %	62,5 %	100,0 %
scan skewed	10	8,9 s	12,3 s	99,0 %	80,0 %	100,0 %

Observations

- Le seul échec initial est business-065 (scan basse résolution) : timeout à 60,0 s, puis succès en 9,2 s.
- Les scans inclinés et bruités restent très solides. La basse résolution est le profil le plus fragile : une ligne produit manquée et une tentative ayant nécessité un retry.
- Le p95 du petit groupe « scan compressé » correspond à un unique appel lent de 42,7 s ; avec N=7, il doit être lu comme un signal de queue longue, pas comme une fréquence stabilisée.

Par langue

Langue	N	p50	Score métier	Parfaits	Type exact	Date exacte
EN	33	8,1 s	99,2 %	87,9 %	87,9 %	100,0 %
FI	33	8,5 s	97,0 %	66,7 %	84,8 %	84,8 %
FR	34	8,0 s	99,2 %	85,3 %	88,2 %	100,0 %

Qualité métier : forces et défauts

100,0 %	100,0 %	100,0 %	99,8 %
fournisseur	numéro document	totaux	rappel lignes

Champ	Exactitude	Interprétation
Type de document	87,0 %	Défaut concentré sur order_confirmation
Date document	95,0 %	5 dates fausses/manquantes sur 100
Référence produit	99,8 %	1 ligne manquée sur scan basse résolution
Quantité	99,6 %	Très robuste aux scans
Prix unitaire	99,8 %	Très robuste aux scans
Total de ligne	99,6 %	Quelques écarts d'arrondi/lecture
Taux de TVA	88,7 %	Point faible secondaire, surtout finnois

Défaut principal : confirmation vs commande

Sur les 12 documents order_confirmation, le type exact n'est correct que dans 1/12 cas. Les numéros, dates de livraison, totaux et lignes sont néanmoins correctement extraits. C'est un problème de classification sémantique du schéma/prompt, pas de lecture du PDF.

Correctif recommandé

- Ajouter une règle déterministe ou un exemple explicite : « accusé / order confirmation » → order_confirmation ; « commande émise » → supplier_order.
- Ajouter un test de non-régression sur les trois langues, puis réexécuter le sous-ensemble de 24 commandes/confirmations.
- Contrôler séparément la date de document et la date de livraison dans le schéma d'annotation.
- Pour la TVA, recalculer le taux à partir des montants lorsque le document fournit HT, taxe et TTC.

Architecture cible et plan d'action

Étape	Décision
1. Entrée	Conserver les validations actuelles de taille et MIME.
2. Lecture	Appeler directement Mistral OCR avec document_annotation et le schéma ToqueHub.
3. Résilience	Sur timeout/réseau/5xx : un retry borné et idempotent ; aucun retry sur erreur fonctionnelle 4xx.
4. Matching	Conserver extractBusinessData et le matching fournisseur/produit.
5. Firecrawl optionnel	Seulement préflight/diagnostic derrière un feature flag ; ne pas envoyer son Markdown au modèle de chat dans le chemin nominal.
6. Observabilité	Mesurer upload, attente, OCR, extraction, matching, persistance et délai UI séparément.

Seuils de suivi suggérés

Indicateur	Seuil d'alerte initial	Cible
Succès premier passage	< 98,5 %	≥ 99 %
Succès après retry	< 99,5 %	≥ 99,8 %
Latence p50 cœur OCR	> 12 s	< 10 s
Latence p95 hors retry	> 20 s	< 15 s
Type de document exact	< 95 %	≥ 97 %
Rappel lignes produit	< 98 %	≥ 99 %

Ce que Firecrawl peut quand même apporter

- Détecter instantanément si un PDF est texte, scanné ou mixte, ainsi que les pages nécessitant un OCR.
- Refuser ou signaler tôt un PDF vide, corrompu ou avec problèmes d'encodage.
- Produire des métriques de qualité d'entrée sans consommer de token distant.
- Servir à d'autres usages de lecture simple où aucun JSON métier fiable n'est requis.

Limites et reproductibilité

Limites à garder en tête

- Le corpus métier est synthétique et contrôlé. Il permet une vérité terrain exacte et des comparaisons appariées, mais ne reproduit pas tous les logos, tampons, fonds colorés ou particularités fournisseurs réels.
- Les documents sont imprimés ; l'écriture manuscrite n'est pas représentée car elle n'est pas le flux principal de factures et bons fournisseur décrit.
- Les temps Mistral dépendent du réseau, de la charge du fournisseur et du compte. Les ordres de grandeur et comparaisons appariées sont plus fiables que la valeur absolue d'une exécution unique.
- Le chronomètre n'inclut pas upload, stockage objet, file de jobs ni délai d'actualisation de l'interface. Si l'expérience réelle est bien plus lente, ces étapes doivent être instrumentées.
- Les intervalles de confiance portent sur les 40 PDF texte du corpus, pas sur l'ensemble futur de documents ToqueHub.

Reproductibilité

Élément	Valeur
Date	2026-08-02 — Europe/Helsinki
Firecrawl	@firecrawl/pdf-inspector 1.11.2
Mistral	mistral-ocr-latest + schéma document_annotation ToqueHub
Timeout nominal	60 s ; retry diagnostique 120 s
Répétitions Firecrawl	5 par document, médiane utilisée
Fichiers bruts	outputs/pdf-ocr-business-benchmark-2026-08-02/
Scripts	benchmarks/pdf-ocr/prepare_business_corpus.py, run_business_benchmark.ts, evaluate_business_results.mjs

Verdict final : ne pas remplacer l'OCR ToqueHub par Firecrawl pour l'analyse métier. Conserver l'annotation structurée en un appel, ajouter un retry ciblé, corriger la classification des confirmations de commande et instrumenter les étapes autour de l'OCR.