

RAPPORT D'EFFICACITÉ

Analyse PDF ToqueHub vs Firecrawl

100 PDF comparés sur la rapidité, la qualité d'extraction, les tableaux, le routage OCR et la fiabilité.

DÉCISION

Conserver Mistral OCR. Ajouter Firecrawl en pré-analyse locale. Ne pas remplacer entièrement le moteur actuel.

100/100

Routage Firecrawl correct

773x

Gain médian sur PDF natifs

99/100

OCR actuel au premier essai

1. Conclusion exécutive

Le remplacement complet est rejeté. Firecrawl n'est pas un moteur OCR : 60 scans et 5 PDF mixtes exigent toujours Mistral. Pour Stocks, la qualité des tableaux métier reste nettement meilleure avec le système actuel.

Firecrawl a classé correctement les 100 documents et a parcouru le corpus en 118,2 ms. Sur les PDF natifs, sa latence médiane est de 2,14 ms, contre 1652 ms pour ToqueHub/Mistral.

Cette vitesse ne suffit pas à justifier un remplacement. Sur les 35 PDF natifs, le score global Firecrawl est 0,829, contre 0,910. Sur les 5 documents métier natifs, l'écart atteint 0,600 contre 0,810.

0,645	1,000	15,6 %
Tableaux métier - Firecrawl	Tableaux métier - Mistral	Temps gagné - hybride protégé

Décision recommandée

- Conserver Mistral OCR comme source de vérité pour factures, BL, commandes et tickets.
- Ajouter Firecrawl avant Mistral pour classifier le PDF, signaler les pages OCR et détecter les tables.
- Tester un fast-path uniquement pour les PDF TextBased fiables et sans table, derrière un feature flag.
- Ajouter une seule relance bornée sur timeout ou erreur réseau.

2. Corpus et méthode

Le corpus contient 100 PDF et 105 pages. Il associe 90 pages publiques uniques d'OpenDataLoader Bench et 15 documents métier synthétiques. Aucune facture réelle, donnée RH ou donnée personnelle du dépôt n'a été envoyée.

Catégorie	PDF	Caractéristiques
native_text	35	Texte natif, tableaux, colonnes, tailles de page variées
scan_clean	18	Raster 200 dpi, compression légère
scan_lowres	18	Raster 96 dpi, contraste réduit
scan_skewed	12	Inclinaison jusqu'à 2,8 degrés
scan_noisy	6	Bruit, flou, contraste réduit
scan_compressed	6	Compression JPEG forte
mixed	5	Deux pages : une native et une scannée

Documents métier

Les 15 documents ToqueHub synthétiques couvrent factures, bons de livraison, confirmations de commande, tickets de caisse et catalogues en français, finnois et anglais. Plusieurs variantes emploient des formats A4, Letter, paysage, ticket étroit, tableaux denses et annotations manuscrites simulées.


Mesures

- NID : similarité du texte et de l'ordre de lecture.
- TEDS : fidélité structurelle et textuelle des tableaux.
- MHS : titres et structure hiérarchique.
- Score global : moyenne des métriques disponibles par document.


Les temps Firecrawl mesurent l'appel local en mémoire après initialisation. Les temps ToqueHub mesurent la classe `MistralClientService.ocrMarkdown` du dépôt et incluent encodage base64, réseau et service Mistral.

3. Qualité et rapidité

Qualité globale selon le scénario (0 à 1)



Temps total séquentiel mesuré ou simulé



4. Résultats détaillés

Catégorie	N	ToqueHub	NID	Médiane	Firecrawl
native_text	35	0,910	0,941	1 652 ms	0,829
scan_clean	18	0,906	0,930	1 674 ms	0,000
scan_lowres	18	0,922	0,943	1 502 ms	0,000
scan_skewed	12	0,814	0,870	1 948 ms	0,000
scan_noisy	6	0,920	0,960	1 768 ms	0,000
scan_compressed	6	0,836	0,915	1 527 ms	0,000
mixed	5	0,871	0,966	1 722 ms	0,453

Lecture des résultats

Les scores Firecrawl à zéro sur les scans ne signifient pas une erreur de classification : le moteur détecte correctement qu'un OCR est nécessaire, puis ne produit volontairement pas de texte. Sur les documents mixtes, il ne restitue que la partie native, d'où un score partiel.

ToqueHub/Mistral réussit 99/100 documents au premier passage. Sa médiane est de 1 711 ms et son p95 de 3 199 ms. Firecrawl gagne le score natif dans 9 cas, Mistral dans 25 cas, avec 1 égalité.

Point de fiabilité : test-068 a atteint le timeout actuel de 60 s. Une relance diagnostique a réussi en 2 046 ms. Le document est lisible; l'échec observé est compatible avec un incident transitoire.

5. Architecture recommandée

Scénario	Local	OCR	Pages OCR	Qualité	Temps	Gain
ToqueHub OCR actuel	0	100	105	0,894	238,7 s	0,0 %
Remplacement complet Firecrawl	100	0	0	0,313	0,1 s	100,0 %
Hybride rapide	35	65	70	0,866	177,1 s	25,8 %
Hybride protégé (sans tables)	20	80	85	0,882	201,3 s	15,6 %

Règle du pilote protégé

1	Classer avec pdf-inspector
2	Local uniquement si TextBased, sans erreur d'encodage, sans page OCR et sans table
3	Sinon, conserver le parcours Mistral OCR actuel
4	Mesurer qualité métier, latence, taux de fallback et coût par page

Dans le corpus, cette règle utilise Firecrawl sur 20 PDF et Mistral sur 80. Elle économise 20 % des appels, 19 % des pages OCR et 15,6 % du temps, avec une baisse de qualité globale de 0,012. Les 15 documents métier restent tous sur Mistral car leurs tableaux sont détectés.

6. Plan de mise en oeuvre

Étape 1 - Instrumenter

Enregistrer type PDF, confiance, pages OCR, tables, durée locale et durée Mistral.

Étape 2 - Ajouter le retry

Une seule relance sur AbortError, timeout ou erreur réseau, avec backoff court.

Étape 3 - Mode observation

Exécuter Firecrawl sans modifier le résultat utilisateur pendant une période de référence.

Étape 4 - Pilote protégé

Activer le fast-path sans table pour un petit pourcentage d'organisations.

Étape 5 - Validation métier

Comparer fournisseur, numéros, dates, totaux, lignes, unités et prix sur des documents anonymisés.

Limites

- Les documents métier sont synthétiques; aucune donnée privée n'a été utilisée.
- Le score mesure la lecture PDF/Markdown, pas chaque champ final de réception de stock.
- Les gains dépendent du taux de PDF natifs en production; il est de 35 % dans ce corpus.
- Les temps Mistral incluent le réseau; les temps Firecrawl sont locaux après initialisation.

Reproductibilité et sources

Firecrawl pdf-inspector 1.11.2, commit a15ec2d68d51dbe6a39d1da688ec7a3f642d846c.

OpenDataLoader Bench, commit 7af1d8f4d0c09f51ea1a5c6ba5f66e993286d109.

Modèle ToqueHub : mistral-ocr-latest.

Artefacts : [outputs/pdf-ocr-benchmark-2026-08-02/](#).

Sources : github.com/firecrawl/pdf-inspector - github.com/opendataloader-project/opendataloader-bench